
Lecture note 5: Machine Learning

프로젝트 기반 딥러닝 이미지처리 한국인공지능아카데미 x Hub Academy


강사 : 김형욱 (hyounguk1112@gmail.com)

Outline



- 1 Introduction
- 2 Intro. To Machine Learning
- 3 선형회귀 알고리즘
- 4 선형분류 알고리즘

From AI to Deep learning




튜링 머신: 인공지능 개념의 시작

Q. 기계가 생각할 수 있는가?

A. "지성 있는 사람이 관찰하여 기계가 진짜 인간처럼 보이게 하는데 성공한다면 확실히 그것은 지능적이라고 간주해야 한다"

- Alan Turing




But, It's not enough now...


인공지능의 정의

- O. 인공지능이란?
- A. 인간처럼 임의의 문제를 해결할 수 있는 기계적 혹은 생체적 장치를 의미함. 그러나 명확하게 합의된 정의는 아직까지 없음.
- Q. 그렇다면 자연지능과의 관계는?
- A. 자연지능은 생존과 번식이라는 자연에 의한 일관된 목표를 달성하기 위해 진화/발전해온 생물체의 기능임. 우리가 아는 범위에서 고도로 어려운 문제를 풀 수 있는 존재는 인간이기 때문에 인간을 모방하는 방향으로 발전해왔으나 기본적으로 '자연지능'의 목적과 달리 인간을 대신하여 복잡한 문제를 해결하는데 목적이 있기 때문에 차별성을 갖는다.

인공지능과 인간지능



인공지능의 개념은 인간지능을 이해하고 모방하는 방향으로 발전해왔다. 그렇다면 인공지능도 지능이 될 수 있을까?



인공지능의 지엽적 정의

A system's ability to correctly interpret external data, to learn from such data, and to use those learnings to achieve specific goals and tasks through flexible adaptation."[1]


Brief history of Artificial Intelligence






Deep Learning Make Machines to have 'Perception'

Deep Learning is Driving Recent Major Breakthroughs in Visual and Speech Recognition Tasks





Now, Machines Learn Deep

Now, Machines Beat Human in Tasks Once Considered Impossible










vs Sedol Lee (Mar. 2016)



Now, Machines Learn Deep

Now, Machines do Tasks which we believed only humans can do



^[1] https://www.smithsonianmag.com/smart-news/ai-system-produces-new-styles-art-180963912/

Explaining Deep Learning



You could think of Deep Learning as the building of learning machines, say pattern recognition systems or whatever, by assembling lots of modules or elements that all train the same way.


So there is a Single Principle to train everything.


IEEE Spectrum, Feb. 2015



Deep learning is a branch of machine learning based on a set of algorithms that attempt to model **high level abstractions** in data by using a deep graph with multiple processing layers, composed of multiple linear and non-linear transformations.


Human vision system






Low-level sensory data


Machine vision system



Artificial Intelligence diagram

From Knowledge-based Approach to Data-driven Approach







Brain-inspired Learning




Learn massive data



simple functions



(Van Essen&Gallant, 1994) Multi-layered



Intro. to ML

머신러닝의 정의

What is Machine Learning?

- Simple answer 인공지능의 한 분야로 데이터로부터 컴퓨터가 특정 문제를 해결하기 위한 함수나 알고리즘을 학습하는 것
- Deep answer

A computer program is said to **learn from experience E** with respect to **task T** and **performance measure P**, if its performance at tasks T, improves with experience E Tom Mitchell, 1957

- · Labeled data
- Direct feedback
- · Predict outcome/future




- · No labels
- No feedback
- · "Find hidden structure"

- Decision process
- · Reward system
- · Learn series of actions


(1) Supervised learning

- 지도학습(Supervised learning) 방식의 학습은 **모델 f(x)** 와 **데이터 x** 그리고 **레이블 y** 로 구성된다.
- 목표는 모델 함수가 데이터를 입력으로 받아 **레이블과 동일한 정답값 또는 분포를 예측**하도록 모델의 파라미터를 최적화시키는 것이다.
- 크게 회귀(Regression)과 분류(Classification)으로 나눌 수 있다.
- 비용(Loss)를 낮추는 것은 학습 과정의 일관된 하나의 목표이다.




(2) Unsupervised learning


- 비지도학습(Unsupervised learning) 방식의 학습은 **모델 f(x)** 와 **데이터 x** 로 구성된다.
- 목표는 모델 함수가 데이터를 입력으로 받아 **각 결과의 패턴 또는 결과들의 분포를 바탕으로** 학습하도록 모델의 파라미터를 최적화시키는 것이다. 이는 대개 문제에 대한 강력한 가정 (Assumptions) 또는 제약(Constraints)를 알고 있기 때문에 가능하다.
- 대표적으로 클러스터링과 생성 모델이 속한다.
- 마찬가지로 비용(Loss)를 낮추는 것은 학습 과정의 일관된 하나의 목표이다.



Supervised Learning


Unsupervised Learning






Supervised Learning


Unsupervised Learning






(3) Reinforcement learning

- 강화학습(Reinforcement learning) 방식의 학습은 **에이전트 f(x,r |s,p)** 와 **관측 정보 x와 보상치 r**로 구성된다.
- 목표는 에이전트가 <u>주어진 환경</u>과 <u>현재의 상태</u>에서 장기적으로 가장 최대한의 보상을 받는 행위를 하도록 자신의 정책(Policy)를 학습하는 것이다.
- 대표적으로 로봇제어와 게임봇이 강화학습의 응용에 속한다.
- 장기적인 기대 보상(reward)를 극대화하는 것이 학습 과정의 일관된 하나의 목표이다.



Machine learning algorithm map



모델과 학습

모델이란?

머신러닝에서 가장 간단한 정의로 모델을 설명하자면, 입력되는 데이터를 처리하는 함수를 의미한다.

일반적으로 프로그램은 입력 데이터를 처리하여 원하는 정보를 얻기 위한 절차를 약속된 명령어로 표현된 것이다. 머신러닝은 이러한 프로그램을 사람이 아닌 데이터로부터 학습이라는 방법으로 구현하는 AI의 한 방법론이다. 학습을 통해 얻어진 함수 형태의 프로그램이 모델이라 할 수 있다.

모델과 학습


학습이란?


학습은 다루는 데이터에 대해 가장 적합한 모델을 찾는(fitting) 과정이다.


임의의 모델은 다양한 문제에 대해 적용할 수 있도록 파라미터를 갖는데 모델의 파라미터가 문제에 얼마나 적합한 지에 따라 분류, 예측에 대한 성능이 결정된다.

파라미터의 문제에 대한 적합성은 <mark>목적함수(Objective function)에</mark> 의해 정의되어 평가된다. 정량화된 수치로 평가하기 위한 것이 바로 비용함수(Loss or Cost or Error function)이다.


머신러닝의 모델 학습 개요










적절한 수준의 복잡도를 가진 모델을 사용하는 것이 중요하다!











Generalization error! 적절한 수준의 Capacity를 갖는 모델을 사용하는 것이 필요!



일반화 오류를 줄이는 방법!

Training set으로는 모델의 Parameter를 학습하고! Validation set으로는 모델의 Hyper-parameter를 튜닝하고! Test set으로 모델의 최종 성능을 통해 모델을 선택(model selection)한다!





선형회귀 알고리즘


선형회귀(Linear regression)

선형회귀(regression) 방법은 종속변수 y와 한 개 이상의 독립변수 x와의 상관 관계를 모델링하는 방법

- Supervised learning
- Labeled dataset을 바탕으로 x를 통해 y를 예측 또는 설명
- The goal of ML is never to make "perfect" guesses, because ML deals in domains where there is no such thing. The goal is to make guesses that are good enough to be useful.







Complexity!

Consider a predictor that looks like this:


$$h(x_1,x_2,x_3,x_4) = \theta_0 + \theta_1 x_1 + \theta_2 x_3^2 + \theta_3 x_3 x_4 + \theta_4 x_1^3 x_2^2 + \theta_5 x_2 x_3^4 x_4^2$$

가설 (hypothesis)

$$h_{ heta}(x) = heta_0 + heta_1 x$$
 ($heta_i$: Parameter)

• 비용 함수 (cost function)

$$J(heta_0, heta_1) = rac{1}{2m} \sum_{i=1}^m (h_ heta(x^i) - y^i)^2$$




오차를 최소화하는 파라미터 (Θ)를 찾는 것이 목적!

= 데이터를 가장 잘 설명하는 모델을 찾는다 (model fitting)

경사하강법(Gradient descent)


비용 함수를 최소화하기 위한 최적화 알고리즘 $J(\theta_0, \theta_1)$ (기울기로 함수의 최소값을 찾는다)

$$J(heta_0, heta_1)=rac{1}{2m}\sum_{i=1}^m(h_ heta(x^i)-y^i)^2$$



$$h_{ heta}(x) = heta_0 + heta_1 x \, (heta_i : \mathsf{Parameter})$$

$$J(heta_0, heta_1) = rac{1}{2m} \sum_{i=1}^m (h_ heta(x^i) - y^i)^2$$




- 1. 파라미터 초기화
- 2. 해당 파라미터에 대한 기울기 계산
 - 3. 파라미터 업데이트
 - 4. 비용 함수가 수렴할 때까지 (최솟값을 가질 때까지) 반복

repeat until convergence {

$$heta_j:= heta_j-lpharac{\partial}{\partial heta_j}J(heta_0, heta_1)$$
 (for j =0 and j =1)

α: learning rate(학습률)


Gradient descent example



$$h_{\theta}(x) = \theta_1 x$$

$$J(heta_1) = rac{1}{2*4} \sum_{i=1}^4 (h_ heta(x^i) - y^i)^2 = rac{1}{8} (26 heta_1^2 - 52 heta_1 + 30)$$

Gradient descent example



$$J(heta_1) = rac{1}{8}(26 heta_1^2 - 52 heta_1 + 30)$$

$$\theta_1$$
 의 초깃값 = 0 , $\alpha=0.1$


```
for i in range(38):
               theta = update theta(theta, alpha)
               print (theta)
           0.65
           0.87750000000000001
           0.957125
           0.98499375
           0.9947478125
           0.998161734375
           0.99935660703125
           0.9997748124609375
           0.9999211843613282
           0.9999724145264649
           0.9999903450842628
           0.9999966207794919
           0.9999988172728221
           0.9999995860454878
           0.9999998551159207
           0.9999999492905722
           0.9999999822517003
           0.999999937880951
           0.999999978258333
           0.9999999992390416
           0.999999997336646
           0.999999999967826
           0.999999999673739
           0.999999999885809
           0.999999999960033
           0.999999999995104
           0.999999999998286
           0.9999999999994
           0.99999999999979
           0.999999999999927
           0.99999999999974
           0.999999999999997
1.0
           0.99999999999999
```

선형분류 알고리즘

로지스틱 회귀(Logistic regression)

로지스틱 회귀(regression) 방법은 이진 분류(binary classification) 문제를 해결하기 위한 알고리즘

- Supervised learning
- Labeled dataset을 바탕으로 x를 통해 x의 클래스(y)를 분류



• 고객이 5년 내에 사망할 확률?


Sex	Age	Diabetes		Life span
Male	20	Yes		65
Female	40	Yes		68
Male	60	No	٠	64







선형회귀 방식으로 이진분류를 하면 안 될까?


Linear Regression?





선형회귀 방식으로 이진분류를 하면 안 될까?






Linear regression for classification?


Problem

1) Threshold

2) Range

선형회귀 방식으로 이진분류를 하면 안 될까?





Linear regression for classification?

Problem

1) Threshold


기준점의 변화 : 기존의 **0.5**를 더 이상 해당 문제에 대한 분류 기준으로 쓸 수 없음. 2) Range

종양이 커지거나, 작을 수록 무한히 음성 또는 양성에 대한 점수가 무한히 커질까? 확률로 나타내자!

시그모이드 함수(Sigmoid function)의 사용

선형회귀 모델의 예측값을 시그모이드 함수에 넣으면 범위를 0~1 사이의 값으로 한정할 수 있다.

이는 확률의 범위와 같으므로 분류 문제의 예측 결과로도 적합



Cost function의 정의

가설 (hypothesis)


$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

• 비용 함수 (cost function)

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^{2}$$




새로운 비용 함수 필요



비용 함수 (cost function)

$$Cost(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1\\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$



• 비용 함수 (cost function)

$$Cost(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1\\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$
$$-\frac{1}{m} \left[\sum_{i=1}^{m} y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right]$$

비용 함수 (오차) 를 최소화 하는 파라미터 (θ) 를 찾는다.

→ 경사 하강법 (Gradient descent)

Logistic regression의 학습

$$J(\boldsymbol{\theta}) = \frac{1}{m} \sum_{i=1}^{m} \mathsf{Cost}(h_{\theta}(x), y)$$

$$Cost(h_{\theta}(\mathbf{x}), y) = -ylog(h_{\theta}(\mathbf{x})) - (1 - y)log(1 - h_{\theta}(\mathbf{x}))$$

Gradient descent for logistic regression:

while not converged { $\theta_j^{\text{new}} = \theta_j^{\text{old}} - \alpha \frac{1}{m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)}) x_j^{(i)} \text{ for } j=0,1,\dots,n$ }

output =
$$\underline{p(Class_{(+)}|X)} = \frac{1}{1+e^{-W^TX}}$$


 θ = \mathbf{y}
If $W^TX > 0$,

then $p(Class_{(+)}|X) > 0.5$ and positive class

then $p(Class_{(+)}|X) < 0.5$ and negative class



이것이 갖는 기하학적 의미?




$$\begin{split} &h_{\theta}(x^{(i)}) = \frac{1}{1+e^{-(\theta^T x^{(i)}+b)}} \\ &J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log(h_{\theta}(x^{(i)})) + (1-y^{(i)}) \log(1-h_{\theta}(x^{(i)})) \right] \\ &= \frac{1}{m} \left[\sum_{i=1}^m -y^{(i)} \log\left(\frac{1}{1+e^{-(\theta^T x^{(i)}+b)}}\right) - (1-y^{(i)}) \log(1-\frac{1}{1+e^{-(\theta^T x^{(i)}+b)}}) \right] \\ &= \frac{1}{m} \left[\sum_{i=1}^m -y^{(i)} (\log 1 - \log(1+e^{-(\theta^T x^{(i)}+b)})) - (1-y^{(i)}) \log\left(\frac{e^{-(\theta^T x^{(i)}+b)}}{1+e^{-(\theta^T x^{(i)}+b)}}\right) \right] \\ &= \frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log(1+e^{-(\theta^T x^{(i)}+b)}) - (1-y^{(i)}) \log(e^{-(\theta^T x^{(i)}+b)}) + (1-y^{(i)}) \log(1+e^{-(\theta^T x^{(i)}+b)}) \right] \\ &= \frac{1}{m} \left[\sum_{i=1}^m (1-y^{(i)}) (\theta^T x^{(i)}+b) + \log(1+e^{-(\theta^T x^{(i)}+b)}) \right] \\ &= \frac{1}{m} \left[\sum_{i=1}^m \log e^{\theta^T x^{(i)}+b} - y^{(i)} (\theta^T x^{(i)}+b) + \log(1+e^{-(\theta^T x^{(i)}+b)}) \right] \\ &= \frac{1}{m} \left[\sum_{i=1}^m \log(e^{\theta^T x^{(i)}+b}+1) - y^{(i)} (\theta^T x^{(i)}+b) \right] \end{split}$$


$$\begin{split} &\frac{\partial J(\theta)}{\partial \theta_j} = \frac{1}{m} [\sum_{i=1}^m \frac{x_j e^{\theta^T x^{(i)} + b}}{e^{\theta^T x^{(i)} + b} + 1} - y^{(i)} x_j] = \frac{1}{m} x_j \sum_{i=1}^m [\frac{1}{1 + e^{-(\theta^T x^{(i)} + b)}} - y^{(i)}] = \frac{1}{m} x_j \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] \\ &\frac{\partial J(\theta)}{\partial b} = \frac{1}{m} [\sum_{i=1}^m \frac{e^{\theta^T x^{(i)} + b}}{e^{\theta^T x^{(i)} + b} + 1} - y^{(i)}] = \frac{1}{m} \sum_{i=1}^m [\frac{1}{1 + e^{-(\theta^T x^{(i)} + b)}} - y^{(i)}] = \frac{1}{m} \sum_{i=1}^m [h_{\theta}(x^{(i)}) - y^{(i)}] \end{split}$$

다중 클래스 분류기(Multi-class classifier)

클래스가 여러 개 일때는 어떻게 할까?



output




Idea transform a vector of numbers into scores for each possible class.


On this case we transform the matrix of numbers (image) on a 1d vector (All spatial information is lost)


On this example our image became an array 4x1, and we need to classify images as (cat,dog,ship)

Linear model f(x,W,b) First one(airplane) Input size among three classifiers \rightarrow Z = $W^TX + b$ 3 classes -1.2 Weights (W) Bias (B) Scores 3x4 3x1 3x1 Input (X) 4x1 Matrix multiplication result 3x1 car classifier Loss The desired scores output for the airplane classifier cat image vector(X) 0 Y (cat) Training How well the parameters W, B map the input to the desired deer classifier output



Idea transform a vector of numbers into scores for each possible class.
On this case we transform the matrix of numbers (image) on a 1d vector (All spatial information is lost)
On this example our image became an array 4x1, and we need to classify images as (cat,dog,ship)







Idea transform a vector of numbers into scores for each possible class.

On this case we transform the matrix of numbers (image) on a 1d vector (All spatial information is lost)

On this example our image became an array 4x1, and we need to classify images as (cat,dog,ship)






Idea transform a vector of numbers into scores for each possible class.


On this case we transform the matrix of numbers (image) on a 1d vector (All spatial information is lost)


On this example our image became an array 4x1, and we need to classify images as (cat,dog,ship)

Linear model f(x,W,b)



아래 영역들에 대한 분류기의 스코어 값은 어떨까?






Idea transform a vector of numbers into scores for each possible class.


On this case we transform the matrix of numbers (image) on a 1d vector (All spatial information is lost)

On this example our image became an array 4x1, and we need to classify images as (cat,dog,ship)

Linear model f(x,W,b)




아래 영역들에 대한 분류기의 스코어 값은 어떨까? 이상적으로 Negative



소프트맥스(Softmax)와 크로스엔트로피(Cross-entropy)

Softmax function




소프트맥스(Softmax)와 크로스엔트로피(Cross-entropy)

Cross entropy

$$H(p,q) = -\sum_x p(x) \, \log q(x).$$

모델이 예측한 데이터에 대한 각 클래스별 확률



실제 정답 : 정답 레이블을 one-hot coding한 형태 (확률 분포의 형태로 만들어주기 위해 사용)

소프트맥스(Softmax)와 크로스엔트로피(Cross-entropy)

왜 Softmax function를 쓸까? 이름은 왜 Softmax일까?

An example. Say K=4, and your log score x is vector [2,4,2,1]. The simple argmax function outputs:

The argmax is the goal, but it's not differentiable and we can't train our model with it: (A simple normalization, which is differentiable, outputs the following probabilities:

That's really far from the argmax! : (Whereas the softmax outputs:

That's much closer to the argmax! Because we use the natural exponential, we hugely increase the probability of the biggest score and decrease the probability of the lower scores when compared with standard normalization. Hence the "max" in softmax.

Thank you!